1.Domaca naloga

2026/2027

Uvod v kriptografijo

35250060

Anna Dankova

Ljubljana, 1000

1.Naloga

Izbran 2.tajnopis : t ="
LISODVČEZAVMŽBGEVCNGŽLLVFRVDŽSLGOKŽCGKČIBAZTAVČVTVBŽHGHGFREŽDŽFIBN
LŽŽLSGNGBŽLGTIPITVNNŽPGLŽMŽBIOČGNNIRGNLGZBŽJŽAVITDVOGBNGNIRPRIULAGE
ITGNIČŽFIPBVTGBČNIHŽINLILŽMŽBILŽNIPGRBVČVLJGČOVEŽBNVČVAVBIDŽBGLGOBGU
LVDEBGNZČERGKLŽFRŽCVBITHZLGAGDFGNČVAVFISGČŽTOŽPGBŽHEVDLŽKNIEIMČIMV
"

Cilj te naloge je analizirati in dešifrirati neznano šifrirano besedilo iz datoteke TAJNOPIS2.txt. V poročilu je sistematično predstavljen postopek kriptoanalize, ki se začne s preverjanjem klasične Cezarjeve šifre, nadaljuje s frekvenčno analizo črk ter n-gramov in zaključi z uspešnim razbitjem monoalfabetske substitucijske šifre.

Caesar cipher :

uporabljen python 3.15.13 in Windows PowerShell 5.1

Koda za preverjanje dolžine in koliko je različnih črk: caesar_check.py

Prompt:
Write a simple Python script to brute-force a Caesar cipher from TAJNOPIS2.txt using the Slovenian alphabet (ABCČDEFGHIJKLMNOPRSŠTUVZŽ), both with and without the letter Š. Also print the text length, unique character count, and Š count.

Dobimo :
Length: 267
Unique characters: 24
Count of Š: 0
Characters outside alphabet: []

Ker v šifriranem besedilu ni bilo črke Š, sem analizo izvedla za dve različici slovenske abecede: standardno 25-črkovno in skrajšano 24-črkovno (brez črke Š). S tem sem pridobila 24 oziroma 25 možnih premikov vseh znakov. Da bi se izognila zamudnemu ročnemu pregledovanju vseh 49 kombinacij, sem uporabila velik jezikovni model (LLM) Qwen3-Coder-30B, ki je samodejno preveril izpisane nize in poiskal morebitno smiselno slovensko besedilo.

```
Alphabet of 25 letters: ABCČDEFGHIJKLMNOPRSŠTUVZŽ
0
LISODVČEZAVMŽBGEVCNGŽLLVFRVDŽSLGOKŽCGKČIBAZTAVČVTVBŽHGHGFREŽDŽFIBNLŽŽLSGNGBŽLGTIPITVNNŽPGLŽMŽBIOČGNN
IRGNLGZBŽJŽAVITDVOGBNGNIRPRIULAGEITGNIČŽFIPBVTGBČNIHŽINLILŽMŽBILŽNIPGRBVČVLJGČOVEŽBNVČVAVBIDŽBGLGOBG
ULVDEBGNZČERGKLŽFRŽCVBITHZLGAGDFGNČVAVFISGČŽTOŽPGBŽHEVDLŽKNIEIMČIMV
1
KHRNČUCDVŽULZAFDUBMFZKKUEPUČZRKFNJZBFJCHAŽVŠŽUCUŠUAZGFGFEPDZČZEHAMKZZKRFMFAZKFŠHOHŠUMMZOFKZLZAHNCFMM
HPFMKFVAZIZŽUHŠČUNFAMFMHPOPHTKŽFDHŠFMHCZEHOAUŠFACMHGZHMKHKZLZAHKZMHOFPAUCUKIFCNUDZAMUCUŽUAHČZAFKFNAF
TKUČDAFMVCDPFJKZEPZBUAHŠGVKFŽFČEFMCUŽUEHRFCZŠNZOFAZGDUČKZJMHDHLCHLU
2
JGPMCTBČUZTKVŽEČTALEVJJTDOTCVPJEMIVAEIBGŽZUSZTBTSTŽVFEFEDOČVCVDGŽLJVVJPELEŽVJESGNGSTLLVNEJVKVŽGMBELL
GOELJEUŽVHVZTGSCTMEŽLELGONOGŠJZEČGSELGBVDGNŽTSEŽBLGFVGLJGJVKVŽGJVLGNEOŽTBTJHEBMTČVŽLTBTZTŽGCVŽEJEMŽE
ŠJTCČŽELUBČOEIJVDOVATŽGSFUJEZECDELBTZTDGPEBVSMVNEŽVFČTCJVILGČGKBGKT
3
IFOLBŠACTVŠJUZDCŠŽKDUIIŠČNŠBUOIDLHUŽDHAFZVTRVŠAŠRŠZUEDEDČNCUBUČFZKIUUIODKDZUIDRFMFRŠKKUMDIUJUZFLADKK
FNDKIDTZUGUVŠFRBŠLDZKDKFNMNFSIVDCFRDKFAUČFMZŠRDZAKFEUFKIFIUJUZFIUKFMDNZŠAŠIGDALŠCUZKŠAŠVŠZFBUZDIDLZD
SIŠBCZDKTACNDHIUČNUŽŠZFRETIDVDBČDKAŠVŠČFODAURLUMDZUECŠBIUHKFCFJAFJŠ
4
HENKASŽBŠUSITVČBSZJČTHHSCMSATNHČKGTZČGŽEVUŠPUSŽSPSVTDČDČCMBTATCEVJHTTHNČJČVTHČPELEPSJJTLČHTITVEKŽČJJ
EMČJHČŠVTFTUSEPASKČVJČJEMLMERHUČBEPČJEŽTCELVSPČVŽJEDTEJHEHTITVEHTJELČMVSŽSHFČŽKSBTVJSŽSUSVEATVČHČKVČ
RHSABVČJŠŽBMČGHTCMTZSVEPDŠHČUČACČJŽSUSCENČŽTPKTLČVTDBSAHTGJEBEIŽEIS
5
GDMJŽRZASTRHŠUCARVICŠGGRBLRŽŠMGCJFŠVCFZDUTSOTRZRORUŠČCČCBLAŠŽŠBDUIGŠŠGMCICUŠGCODKDORIIŠKCGŠHŠUDJZCII
DLCIGCSUŠEŠTRDOŽRJCUICIDLKLDPGTCADOCIDZŠBDKUROCUZIDČŠDIGDGŠHŠUDGŠIDKCLURZRGECZJRAŠUIRZRTRUDŽŠUCGCJUC
PGRŽAUCISZALCFGŠBLŠVRUDOČSGCTCŽBCIZRTRBDMCZŠOJŠKCUŠČARŽGŠFIDADHZDHR
6
FČLIZPVŽRŠPGSTBŽPUHBSFFPAKPZSLFBIESUBEVČTŠRNŠPVPNPTSCBCBAKŽSZSAČTHFSSFLBHBTSFBNČJČNPHHSJBFSGSTČIVBHH
ČKBHFBRTSDSŠPČNZPIBTHBHČKJKČOFŠBŽČNBHČVSAČJTPNBTVHČCSČHFČFSGSTČFSHČJBKTPVPFDBVIPŽSTHPVPŠPTČZSTBFBITB
OFPZŽTBHRVŽKBEFSAKSUPTČNCRFBŠBZABHVPŠPAČLBVSNISJBTSCŽPZFSEHČŽČGVČGP
7
ECKHVOUZPSOFRŠAZOTGAREEOŽJOVRKEAHDRTADUCŠSPMSOUOMOŠRBABAŽJZRVRŽCŠGERREKAGAŠREAMCICMOGGRIAERFRŠCHUAGG
CJAGEAPŠRČRSOCMVOHAŠGAGCJIJCNESAZCMAGCURŽCIŠOMAŠUGCBRCGECERFRŠCERGCIAJŠOUOEČAUHOZRŠGOUOSOŠCVRŠAEAHŠA
NEOVZŠAGPUZJADERŽJRTOŠCMBPEASAVŽAGUOSOŽCKAURMHRIAŠRBZOVERDGCZCFUCFO
8
DBJGUNTVORNEPSŽVNŠFŽPDDNZINUPJDŽGČPŠŽČTBSROLRNTNLNSPAŽAŽZIVPUPZBSFDPPDJŽFŽSPDŽLBHBLNFFPHŽDPEPSBGTŽFF
BIŽFDŽOSPCPRNBLUNGŽSFŽFBIHIBMDRŽVBLŽFBTPZBHSNLŽSTFBAPBFDBDPEPSBDPFBHŽISNTNDCŽTGNVPSFNTNRNSBUPSŽDŽGSŽ
MDNUVSŽFOTVIŽČDPZIPŠNSBLAODŽRŽUZŽFTNRNZBJŽTPLGPHŽSPAVNUDPČFBVBETBEN
9
ČAIFTMŠUNPMDORZUMSEZOČČMVHMTOIČZFCOSZCŠARPNKPMŠMKMROŽZŽZVHUOTOVAREČOOČIZEZROČZKAGAKMEEOGZČODORAFŠZEE
AHZEČZNROBOPMAKTMFZREZEAHGHALČPZUAKZEAŠOVAGRMKZRŠEAŽOAEČAČODORAČOEAGZHRMŠMČBZŠFMUOREMŠMPMRATORZČZFRZ
LČMTURZENŠUHZCČOVHOSMRAKŽNČZPZTVZEŠMPMVAIZŠOKFOGZROŽUMTČOCEAUADŠADM
```

User: "Check if any line contains coherent Slovenian text after Caesar cipher decryption."
AI: "No coherent Slovenian text found in any line.
All lines contain only encrypted character sequences, not meaningful Slovenian words or sentences."

Samodejna analiza z modelom LLM je pokazala, da nobena izmed testiranih kombinacij ne tvori razumljivega besedila v slovenskem jeziku. S tem lahko zanesljivo izključimo možnost, da je datoteka TAJNOPIS2.txt zaščitena s klasično Cezarjevo šifro.

Ker je bila na podlagi samodejne analize z modelom LLM možnost uporabe Cezarjeve šifre zanesljivo izključena, v naslednjem koraku prehajam na analizo frekvence črk in indeksa sovpadanja (IC), da preverim možnost uporabe splošne substitucijske šifre.

Frekvenčna analiza črk in izračun indeksa sovpadanja (IC):

Koda : freq_check.py

Prompt: Write a simple beginner-friendly Python script that reads text from a UTF-8 file named "TAJNOPIS2.txt", counts the frequency of each character, prints the characters sorted from most frequent to least frequent, and then calculates and prints the total text length and the Index of Coincidence (IC).

Cipher Letter	Frequency	Share %
G	30	11.24%
Ž	28	10.49%
I	24	8.99%
V	24	8.99%
L	19	7.12%
B	19	7.12%
N	18	6.74%
Č	13	4.87%
E	9	3.37%
T	9	3.37%
D	8	3.00%
A	8	3.00%
R	8	3.00%
O	7	2.62%
F	7	2.62%
P	6	2.25%
Z	5	1.87%
M	5	1.87%
H	5	1.87%
S	4	1.50%
K	4	1.50%
C	3	1.12%
J	2	0.75%
U	2	0.75%

Po zagonu skripte v ukazni vrstici program izpiše število pojavitev posamezne črke (od najpogostejše do najredkejše), skupno dolžino tajnopisa (267 znakov) ter izračunano vrednost indeksa sovpadanja (IC). Ta znaša 0,0619, kar je bistveno višje od vrednosti za naključno besedilo (približno 0,04) in trdno potrjuje prisotnost naravnega jezika.

Glede na to, da je besedilo precej kratko, tako visoka vrednost kaže na uporabo monoalfabetske ali transpozicijske šifre, saj obe ohranjata frekvenco črk. Hkrati rezultat zanesljivo izključuje uporabo kompleksnejših polialfabetskih metod, kot je Vigenèrova šifra, ki bi indeks sovpadanja znižale bližje vrednosti 0,04.

Najpogostejše črke:

Koda za preverjanje napogostejših črk: top4_check.py

Prompt: Write a simple beginner Python script to read ciphertext from TAJNOPIS2.txt (utf-8), count each character using a basic for loop and dictionary (no libraries), find the top 4 most frequent letters, and print their counts, total sum, and percentage of the whole text.

Dobimo:

G 30
Ž 28
I 24
V 24
Top 4 letters: ['G', 'Ž', 'I', 'V']
Together: 106 of 267
Percent: 39.70037453183521

Skupaj te štiri črke predstavljajo 106 znakov, kar znaša 39,7 % celotnega besedila.

Ker v običajnem slovenskem besedilu najpogostejše črke (E, A, I, O) prav tako predstavljajo približno 35–40 % vseh črk, ta rezultat močno nakazuje, da gre za enostavno substitucijsko šifro (kjer vsako črko odprtega besedila vedno zamenja ista črka tajnopisa).

Preverjanje parov črk:

Koda za preverjanje vseh možnih parov črk : bigram_check.py

Prompt: Write a very basic Python code to read TAJNOPIS2.txt (utf-8) and count all pairs of neighboring letters using a simple dictionary and a for loop. Don't use any imports. Print the top 10 most common pairs.

Frequent N-grams	Count	Frequency %
GN	7	2,63%
LŽ	6	2,26%
NI	6	2,26%
AV	5	1,88%
ŽB	5	1,88%
LG	5	1,88%
VČ	4	1,50%
BG	4	1,50%
ČV	4	1,50%
BŽ	4	1,50%

AV = JE. Ujema se po deležu. Dodatni argument: A se pojavi 8-krat, J pa je v slovenščini precej pogosta črka, tako da je to za 267 črk verjetno. V se pojavi 24-krat, kar je ravno raven pogostega samoglasnika E. To je samo hipoteza.

https://www.sttmedia.com/syllablefrequency-slovenian

Preverjamo če je AV =JE :

Letter	Frequency
JE	2.04 %
ST	1.83 %
NI	1.63 %
NA	1.58 %
PO	1.55 %
RA	1.53 %
IN	1.41 %
AN	1.39 %
PR	1.37 %
EN	1.24 %
OV	1.21 %
RE	1.20 %
NO	1.19 %
NE	1.17 %
JA	1.14 %
KO	1.14 %
AL	1.12 %
TE	1.07 %
LI	1.05 %
LA	1.01 %
ZA	0.99 %
TI	0.98 %
VE	0.97 %
NJ	0.95 %
OD	0.93 %
SK	0.93 %

Koda ki pregleda po 4 crke pred in po para AV : av_context_check.py

Prompt : Write very basic Python code to read TAJNOPIS2.txt (utf-8), find every pair "AV" and print 4 letters before and 4 letters after it. Don't use any imports.

Dobimo:
VČEZ [AV] MŽBG
BAZT [AV] ČVTV
BŽJŽ [AV] ITDV
NVČV [AV] BIDŽ
GNČV [AV] FISG

Kaj se vidi iz izpisa
Pred AV so črke Z, T, Ž, V, V, za njo pa M, Č, I, B, F. Če je AV samostojna beseda JE, potem je pred njo konec ene besede, za njo pa začetek naslednje.

Štirje od petih kontekstov imajo zraven AV še en V: VČEZ, ČVTV, NVČV, GNČV. To je normalno, glede na to, da je V pogosta črka (24-krat).

Preverim še, kjer se pojavi črka A. Imamo samo 8 črk A v tajnopisu:

Koda za preverjanje vseh 8 mest kje se pojavi A : letter_context_check.py

ČIB [A] ZTA
IUL [A] GEI
ZLG [A] GDF

Če je A = J, potem na teh treh mestih J stoji pred Z ali G. V slovenščini je J skoraj vedno zraven samoglasnika. To pomeni, da bi morala biti tako G kot Z samoglasnika.

Za G je to precej verjetno, ker je G najpogostejša črka (30-krat) in smo že prej predvidevali, da je samoglasnik.

Preverjamo črke po eno :

Črka G :

ČEZ [A] VMŽ
AZT [A] VČV
ŽJŽ [A] VIT
VČV [A] VBI
NČV [A] VFI

Da preverimo, sem zamenjala črki A -> j in V -> e in G-> a.
Najpogostejša črka v jeziku

Koda za zamenjavo : substitute.py
Kodo bom dopolnjevala za vso zamenjavo črk.

Prompt: Write a short Python script to read TAJNOPIS2.txt (UTF-8) and decrypt it using a simple substitution dictionary ({'A': 'j', 'V': 'e'}), leaving unmapped characters unchanged, then print the result.

t =
(LISODeČEZjeMŽBaEeCNaŽLLeFReDŽSLaOKŽCaKČIBjZTjeČeTeBŽHaHaFREŽDŽFIBNLŽŽLSaNa
BŽLaTIPITeNNŽPaLŽMŽBIOČaNNIRaNLaZBŽJŽjeITDeOaBNaNIRPRIULjaEITaNIČŽFIPBeTaBČNI
HŽINLILŽMŽBILŽNIPaRBeČeLJaČOeEŽBNeČejeBIDŽBaLaOBaULeDEBaNZČERaKLŽFRŽCeBITH
ZLajaDFaNČejeFISaČŽTOŽPaBŽHEeDLŽKNIEIMČIMe)

Črka L:

NA	1.58 %

Ker je G → a, lahko preverimo par LG, se pojavi 5x in 1,88% v tajnopisu.
Predpostavim, da je L → n.
Dodam novo črko n v kodo : substitute.py

t =
(nISODeČEZjeMŽBaEeCNaŽnneFReDŽSnaOKŽCaKČIBjZTjeČeTeBŽHaHaFREŽDŽFIBNnŽŽnSaN
aBŽnaTIPITeNNŽPanŽMŽBIOČaNNIRaNnaZBŽJŽjeITDeOaBNaNIRPRIUnjaEITaNIČŽFIPBeTaBČ
NIHŽINnInŽMŽBInŽNIPaRBeČenJaČOeEŽBNeČejeBIDŽBanaOBaUneDEBaNZČERaKnŽFRŽCeBI
THZnajaDFaNČejeFISaČŽTOŽPaBŽHEeDnŽKNIEIMČIMe)

Še niso vidne besede. Razumljivih besed ni videti. Črke skupaj so videti kot odlomki fraz v slovenščini. Ni veliko samoglasnikov zapored.

Črka Ž:

NI	1.63 %

LŽ	6	2.26%

Preverjeno s pomočjo LŽ v tajnopisu. Že poznamo, da je LG ->na, zato LŽ -> ni.

Dodam novo črko Ž v kodo : substitute.py

t =
(nISODeČEZjeMiBaEeCNainneFReDiSnaOKiCaKČIBjZTjeČeTeBiHaHaFREiDiFIBNniinSaNaBinaTIPIT
eNNiPaniMiBIOČaNNIRaNnaZBiJijeITDeOaBNaNIRPRIUnjaEITaNIČiFIPBeTaBČNIHiINnInIMiBInINI
PaRBeČenJaČOeEiBNeČejeBIDiBanaOBaUneDEBaNZČERaKniFRiCeBITHZnajaDFaNČejeFISaČiTOi
PaBiHEeDniKNIEIMČIMe)

Zamenjala sem črko Ž -> i. Še niso vidne besede. Lahko vidimo skupke črk, kot so »ainne«, »niin«, »eje«. To še vedno izgleda kot slovenski jezik. Take končnice so lahko prisotne, ker smo našli samo samoglasnike, samoglasniki v slovenskem jeziku pa so najpogostejši.

Cipher Letter	Frequency	Share %	Hypothesis	Status	Confirmed
G	30	11.24%	A		Najpogostejša črka v jeziku.
Ž	28	10.49%	I		Preverjeno s pomočjo LŽ v tajnopisu. Že poznamo, da je L ->na, zato LŽ -> ni.
I	24	8.99%	O		
V	24	8.99%	E		Preverjeno s pomočjo JE, ki je najpogostejši par v slovenskem jeziku.
L	19	7.12%	N		Preverjeno s pomočjo LG v tajnopisu. Že poznamo, da je G -> a, zato LG -> na.
B	19	7.12%	L		Črka L je na 6. mestu po pogostosti v slovenskem jeziku, zato jo preverjam kot pogosto. Predpostavim, da je B -> l. Se pojavi pri BŽ(1,5%) in ŽB(1,88%)
N	18	6.74%			
Č	13	4.87%			
E	9	3.37%			
T	9	3.37%			
D	8	3.00%			
A	8	3.00%	J		Preverjeno s pomočjo JE, ki je najpogostejši par v slovenskem jeziku.

Črka B :

LI	1.05 %

Črka L je na 6. mestu po pogostosti v slovenskem jeziku, zato jo preverjam kot pogosto. Predpostavim, da je B -> l. Se pojavi pri BŽ(1,5%) in ŽB(1,88%). Črko Ž pa ze poznamo da je I Dodam novo črko B v kodo : substitute.py

t =
(nISODeČEZjeMilaEeCNainneFReDiSnaOKiCaKČIljZTjeČeTeliHaHaFREiDiFIlNniinSaNalinaTIPITeN
NiPaniMiIIOČaNNIRaNnaZliJijeITDeOalNaNIRPRIUnjaEITaNIČiFIPleTalČNIHiINnInIMiIInINIPaRleČe
nJaČOeEilNeČejeIIDilanaOlaUneDElaNZČERaKniFRiCeIITHZnajaDFaNČejeFISaČiTOiPaliHEeDniKNI
EIMČIMe)

Preverimo črko po 3 :

Koda za preverjanje vseh možnih parov po 3 črk : trigram_check.py

Prompt: "Modify a basic Python loop script without imports to read the first 267 characters of TAJNOPIS2.txt, count all overlapping 3-letter sequences, and print all frequencies in English."

Črka M :

Lahko odkrijemo črko M, ker ze požnamo MŽB. M->b.

t=
(nISODeČEZjebilaEeCNainneFReDiSnaOKiCaKČIljZTjeČeTeliHaHaFREi
DiFIlNniinSaNalinaTIPITeNNiPanibilIOČaNNIRaNnaZliJijeITDeOalNaNI
RPRIUnjaEITaNIČiFIPleTalČNIHiINnInibilIniNIPaRleČenJaČOeEilNeČeje
lIDilanaOlaUneDElaNZČERaKniFRiCelITHZnajaDFaNČejeFISaČiTOiPali
HEeDniKNIEIbČIbe)

Zdaj lahko vidimo besedi »je bila«.
Preostale skupine po tri črke (trigrame) je že težje primerjati z dejanskimi kombinacijami v slovenščini. V običajnem jeziku so besede ločene s presledki, naše besedilo pa je zapisano strnjeno. Zaradi tega nimamo več neposrednih ujemanj.

Naslednji korak:
Namesto preverjanja po parih je zdaj smiselno v besedilo vstavljati posamezne črke. Tako bomo lahko sproti preverjali, ali se pojavljajo nove smiselne besede in ali besedilo postaja berljivo.

MŽB 3
VČV 3
ŽBG 2
LGO 2
BŽH 2
ŽFI 2
GBŽ 2
ŽPG 2
LŽM 2
ŽMŽ 2
ŽBI 2
NIR 2
GNI 2
ILŽ 2
ČVA 2
VAV 2
VBI 2

Letter	Frequency
ANJ	0.69 %
PRE	0.65 %
OST	0.62 %
NJE	0.55 %
EGA	0.53 %
STI	0.49 %
PRI	0.48 %
STA	0.45 %
ALI	0.45 %
RAV	0.38 %
CIJ	0.38 %
NIH	0.38 %
RED	0.37 %
IST	0.36 %
NOS	0.35 %
STO	0.31 %
RAZ	0.30 %
SKE	0.30 %
TEM	0.30 %
BIL	0.29 %
SKI	0.29 %
LET	0.29 %
DEL	0.29 %

Črka I :

Zamenjala sem črko I-> o. Bila je pozabljena. Je na pravem mestu, ker je ena izmed najpogostejših črk v abecedi in je samoglasnik.

Dodam novo črko I v kodo : substitute.py
t=
(noSODeČEZjebilaEeCNainneFReDiSnaOKiCaKČoljZTjeČeTeliHaHaFREiDiFolNni
inSaNalinaToPoTeNNiPanibiloOČaNNoRaNnaZliJijeoTDeOalNaNoRPRoUnjaEo
TaNoČiFoPleTalČNoHioNnonibiloniNoPaRleČenJaČOeEilNeČejeloDilanaOlaUn
eDElaNZČERaKniFRiCeloTHZnajaDFaNČejeFoSaČiTOiPaliHEeDniKNoEobČobe)

Zdaj, ko sem zamenjala zadnji samoglasnik, je smiselno prebrati besedilo od začetka. Sproti bom zamenjevala še preostale šifrirane črke s tistimi, ki se mi zdijo najbolj logične. Če se bo iz teh kombinacij sestavila smiselna beseda in bo celotno besedilo postalo berljivo, bom štela, da sem zadela pravo črko.

Črka S :

Zamenjala sem črko S -> č. Beseda »noS« je podobna besedi »noč«. Preverim, če je to prav. Dodam novo črko S v kodo : substitute.py

t=
(nočODeČEZjebilaEeCNainneFReDičnaOKiCaKČoljZTjeČeTeliHaHaFREiDiFolNniinčaNalinaToPo
TeNNiPanibiloOČaNNoRaNnaZliJijeoTDeOalNaNoRPRoUnjaEoTaNoČiFoPleTalČNoHioNnonibil
oniNoPaRleČenJaČOeEilNeČejeloDilanaOlaUneDElaNZČERaKniFRiCeloTHZnajaDFaNČejeFočaČ
iTOiPaliHEeDniKNoEobČobe)

Črka O:

Zdaj imamo na začetku besedo »noč«. Za njo od vseh naših črk najbolj logično sledi »v«, tako da dobimo »noč v«. O->v

Dodam novo črko O v kodo : substitute.py

t=
(nočvDeČEZjebilaEeCNainneFReDičnavKiCaKČoljZTjeČeTeliHaHaFREiDiFolNniinčaNalinaToPo
TeNNiPanibilovČaNNoRaNnaZliJijeoTDevalNaNoRPRoUnjaEoTaNoČiFoPleTalČNoHioNnonibil
oniNoPaRleČenJaČveEilNeČejeloDilanavlaUneDElaNZČERaKniFRiCeloTHZnajaDFaNČejeFočaČ
iTviPaliHEeDniKNoEobČobe)

Črka Č:

Zamenjala sem črko Č -> s. V besedilu vidimo »Čeje«, kar izgleda, kot da je »se je«. To lahko pogosto srečamo v besedilih.

Dodam novo črko Č v kodo : substitute.py

t=
(nočvDesEZjebilaEeCNainneFReDičnavKiCaKsoljZTjeseTeliHaHaFREiDiFolNniinčaNalinaToPoT
eNNiPanibilovsaNNoRaNnaZliJijeoTDevalNaNoRPRoUnjaEoTaNosiFoPleTalsNoHioNnonibilon
iNoPaRlesenJasveEilNesejeloDilanavlaUneDElaNZsERaKniFRiCeloTHZnajaDFaNsejeFočasiTviP
aliHEeDniKNoEobsobe)

Črka F:

Zamenjala sem F->p. V tajnopisu vidimo besedo »Fočasi«, kar je podobno besedi »počasi«.

Dodam novo črko F v kodo : substitute.py

t=
(nočvDesEZjebilaEeCNainnepReDičnavKiCaKsoljZTjeseTeliHaHapREiDipolNniinčaNalinaToPo
TeNNiPanibilovsaNNoRaNnaZliJijeoTDevalNaNoRPRoUnjaEoTaNosipoPleTalsNoHioNnonibilo
niNoPaRlesenJasveEilNesejeloDilanavlaUneDElaNZsERaKnipRiCeloTHZnajaDpaNsejepočasiTv
iPaliHEeDniKNoEobsobe)

Šifrirano besedilo smo uspešno začeli dešifrirati s pomočjo ročne in polavtomatske frekvenčne analize. Ugotovili smo, da gre za enostavno monoalfabetsko substitucijsko šifro. Celoten ključ odkrijemo postopoma.

Cipher Letter	Frequency	Share %	Hypothesis	Status	Confirmed
G	30	11.24%	A		Najpogostejša črka v jeziku.
Ž	28	10.49%	I		Preverjeno s pomočjo LŽ v tajnopisu. Že poznamo, da je L ->na, zato LŽ -> ni.
I	24	8.99%	O		Preverjeno, da je ena izmed najpogostejših črk v abecedi.
V	24	8.99%	E		Preverjeno s pomočjo JE, ki je najpogostejši par v slovenskem jeziku.
L	19	7.12%	N		Preverjeno s pomočjo LG v tajnopisu. Že poznamo, da je G -> a, zato LG -> na.
B	19	7.12%	L		Črka L je na 6. mestu po pogostosti v slovenskem jeziku, zato jo preverjam kot pogosto. Predpostavim, da je B -> l. Se pojavi pri BŽ(1,5%) in ŽB(1,88%)
N	18	6.74%	K		
Č	13	4.87%	S		V tajnopisu se vidita besedi skupaj »Čeje«, kar je podobno besedama »se je«.
E	9	3.37%			
T	9	3.37%	D		
D	8	3.00%			
A	8	3.00%	J		Preverjeno s pomočjo JE, ki je najpogostejši par v slovenskem jeziku.
R	8	3.00%			
O	7	2.62%	V		Na začetku je beseda »noč«. Za njo od vseh naših črk najbolj logično sledi »v«, tako da dobimo »noč v«.
F	7	2.62%	P		V tajnopisu vidimo besedo »Fočasi«, kar je podobno besedi »počasi«.
P	6	2.25%	G		
Z	5	1.87%			
M	5	1.87%	B		Preverjeno s pomocjo MŽB . Smo ze poznali ŽB
H	5	1.87%			
S	4	1.50%	Č		Preverjeno. Našli smo besedo noč.
K	4	1.50%			
C	3	1.12%			
J	2	0.75%			
U	2	0.75%			

Zdaj smo dobili takšno tabelo z razvozlanimi črkami. Zaenkrat zagotovo poznamo 12 od 24 črk – polovica je torej že rešena. Z rumeno so označene vrstice pri tistih črkah, ki jih v našem šifriranem besedilu še nisem uporabila.

Črka N:

Opazila sem, da po N pogosto sledi o, kar paše za besedo "ko".

Dodam novo črko N v kodo : substitute.py

t=
(nočvDesEZjebilaEeCkainnepReDičnavKiCaKsoljZTjeseTeliHaHapREiDipolkniinčakalinaToPoTekki
PanibilovsakkoRaknaZliJijeoTDevalkakoRPRoUnjaEoTakosipoPleTalskoHioknonibilonikoPaRlesen
JasveEilkesejeloDilanavlaUneDElakZsERaKnipRiCeloTHZnajaDpaksejepočasiTviPaliHEeDniKkoEob
sobe)

Zdaj se že začenjajo videti besede, zato jih menjam skupaj po besedah.

Črke D, E, Z:

Predlogu »v« v slovenščini običajno sledi samostalnik, ki označuje kraj. Imamo 5-črkovno besedo DesEZ. Najbolj logična in pogosta beseda, ki ustreza temu morfemu in se ujema z danim kontekstom (»noč v [kraju] je bila«), je mestu.

D → m
E → t
Z → u
Dodajam nove črke posebej v kodo : substitute.py
Na koncu dobim :
t=
(nočvmestujebilateCkainnepRemičnavKiCaKsoljuTjeseTeliHaHapRtimipolkniinčakalinaToPoTekki
PanibilovsakkoRaknauliJijeoTmevalkakoRPRoUnjatoTakosipoPleTalskoHioknonibilonikoPaRlesen
JasvetilkesejelomilanavlaUnemtlakustRaKnipRiCeloTHunajampaksejepočasiTviPaliHtemniKkotob
sobe)

Črke C, P, R:

V tem odlomku iz tajniposa2: »jebilateCkainnepRemična« se vidi besedilo »je bila težka in nepremična«. Vstavimo te črke in preverimo. Podobno je tle “nibilonikoPaR”

C->Ž
P->g
R->r

Dodajam nove črke posebej v kodo : substitute.py

t=
(nočvmestujebilatežkainnepremičnavKižaKsoljuTjeseTeliHaHaprtimipolkniinčakalinaTogoTekkiga
nibilovsakkoraknauliJijeoTmevalkakorgroUnjatoTakosipogleTalskoHioknonibilonikogarlesenJasv
etilkesejelomilanavlaUnemtlakustraKnipriželoTHunajampaksejepočasiTvigaliHtemniKkotobsobe)

Črke K, T, H, U:

V tem odlomku besedila »KižaKsoljuTjeseTeliHaHaprtimi« lahko spet razberemo nove besede, če zamenjamo črke. Opazi se, da je prvih 5 črk podobnih besedi »hišah«, ampak 3. črka pri nas je že Ž. Če pa bi to zamenjali s Š, bi potem v besedi »težka« stal Š namesto Ž.

Zamenjamo črko T -> d in dobimo besedo ljudje. Nato dobimo besede »hišah so ljudje sedeli za zaprtimi«. Zdaj imamo že smiselno besedilo.
Zaenkrat bom pustila C -> Ž.

K-> h
T->d
H->z

Dodajam nove črke posebej v kodo : substitute.py

t=
(nočvmestujebilatežkainnepremičnavhižahsoljudjesedelizazaprtimipolkniinčakalinadogodekki
ganibilovsakkoraknauliJijeodmevalkakorgroUnjatodakosipogledalskozioknonibilonikogarlesenJ
asvetilkesejelomilanavlaUnemtlakustrahnipriželodzunajampaksejepočasidvigaliztemnihkotobs
obe)

Postalo je jasno, da C -> ž ni pravilno, saj naprej naletimo na besedo »kakorgroUnja« in to je beseda »grožnja«. To pomeni, da je U -> ž, C pa je š.
U->ž

Črka J:

nočvmestujebilateškainnepremičnavhišahsoljudjesedelizazaprtimipolkniinčakalinadogodekkig
anibilovsakkoraknaulicijeodmevalkakorgrožnjatodakosipogledalskozioknonibilonikogarlesenc
asvetilkesejelomilanavlažnemtlakustrahniprišelodzunajampaksejepočasidvigaliztemnihkotobs
obe

Opazimo, da J-> c , ker “uliJi”-> ulici

Končno besedilo :

Na začetku popravim besedo “težka”

«Noč v mestu je bila težka in nepremična. V hišah so ljudje sedeli za zaprtimi polkni in čakali na dogodek, ki ga ni bilo. Vsak korak na ulici je odmeval kakor grožnja, toda ko si pogledal skozi okno, ni bilo nikogar. Le senca svetilke se je lomila na vlažnem tlaku. Strah ni prišel od zunaj, ampak se je počasi dvigal iz temnih kotov sobe.»

Metodologija in uporabljena orodja

Za analizo in dešifriranje datoteke tajnopis2.txt so bile napisane skripte v programskem jeziku Python (različica 3.15.13), ki so se izvajale v ukazni vrstici (terminalu). Postopek razreševanja je potekal v naslednjih korakih:

- **Statistična analiza**: Najprej so bile izračunane osnovne metrike šifriranega besedila, vključno z dolžino niza ter frekvenco pojavljanja posameznih črk, parov (bigramov) in trojk (trigramov).
- **Frekvenčna substitucija**: S primerjavo pridobljenih frekvenc s statistiko dejanskega slovenskega jezika so bili najprej identificirani najpogostejši samoglasniki, nato pa so se s pomočjo analiz parov določile še nekatere druge črke.
- **Kontekstualno dopolnjevanje**: Ko statistična ujemanja niso več zadoščala in je bil šifrogram napol razrešen, se je nadaljnje dešifriranje opiralo na branje delno razkritega besedila ter logično dopolnjevanje manjkajočih črk v prepoznavnih slovenskih besedah.
- **Iterativna gradnja ključa**: Odkrite črke in ključ so se sproti dodajali v skripto substitute.py. Ta iterativni postopek je privedel do končne različice kode, ki datoteko v celoti in samodejno dešifrira.

Celotna in podrobna tabela s frekvenčno analizo ter analizami n-gramov je preobsežna za neposredno vključitev v ta PDF dokument, zato je priložena ločeno v ZIP datoteki (kot preglednica).Prompte za kodo v pythonu sem generirala s pomocjo Gimini Flash in Perplexity.

Ker je besedilo precej kratko (samo 267 znakov), nekaterih črk v njem sploh ni. V samem tajnopisu na primer sploh ni uporabljena črka Š. V mojem končnem ključu pa manjka črka F, zato, ker v pravem besedilu ni nobene besede s to črko.

Manjkajoče črke in napake v tajnopisu

Med dešifriranjem sem opazila dve besedi, ki sta narobe zapisana.

- **»TEŠKA«** namesto »težka«: V šifropisu je tukaj uporabljena črka C. Ta črka povsod drugje v besedilu pomeni Š (na primer v besedah »hišah« in »prišel«). Če bi avtor hotel pravilno napisati Ž, bi moral uporabiti šifrirano črko U (tako kot v besedah »grožnja« in »vlažnem«). Avtor se je očitno zmotil in zakodiral besedo »teška«.
- **»KOTOB«** namesto »kotov«: Čisto na koncu besedila je še ena napaka. Uporabljena je šifrirana črka M, ki v mojem ključu povsod pomeni B. Morala pa bi biti uporabljena črka O, ki pomeni V. Avtor je pri tej zadnji besedi verjetno slučajno zamenjal črki B in V.

Zaključek

Nalogo sem uspešno rešila. S pomočjo frekvenčne analize, opazovanja parov črk in logičnega sklepanja iz konteksta mi je uspelo razbiti to substitucijsko šifro in poiskati celoten ključ. Kljub manjšim posebnostim pri črkovanju nekaterih besed, je dešifrirano besedilo popolnoma smiselno in potrjuje, da je najdeni ključ pravilen.